生物学的アプローチに基づいたLIFネットワークの重みの漏れ拡散のWine-TowerモデルによりSpikingNeuralNetworkにおけるDead-Neuron問題の解決の検証

Fumiaki INOUE
finou882@github

Abstract

スパイキングニューラルネットワーク（SNN）の訓練における根本的な課題は「Dead-Neuron」問題であり、これはニューロンが発火閾値に達せず、一貫してスパイク生成を停止する状態を指す [5]。SNN において、スパイクの欠如は単に計算効率の低下を招くだけでなく、時間軸に沿った情報伝達が完全に遮断されることを意味する [5]。この現象は、代替勾配を用いた時間的逆伝播（BPTT）において構造的なボトルネックとなり、活動していないニューロンが消失勾配を引き起こすため、深層構造の最適化は事実上不可能となります。したがって、強化学習のような複雑な課題において、SNN は局所最適的な行動（例: 左手の法則）に陥りやすくなります。これらの沈黙したニューロンの不可逆的な性質は、ネットワークの表現能力や適応力を永続的に低下させ、堅牢かつ多様な探索を実現する上で重大な障壁を生み出します。

***K*eywords** Spiking Neural Network · Dead-Neuron · Wine-Tower · Lifelong Learning

1 Introduction

1.1 Proposal

LIF[1] 特有の電位の減衰を近くの細胞に分配する拡散モデル (QRDM, Question-rasing Diffusion Model) を提案する。これはすでに勝っているニューロンから常に漏れる電位を近くのニューロンに拡散することで、WTA による学習の結果を維持しつつすでに死んだニューロンに発火の機会を与えることで、Dead-Neuron 問題の解消に寄与するという仮説を立てる。

Mathematical Formulation

提案する Wine-Tower モデルにおける、死んだニューロン i への補助電流 $I_{assist,i}$ は、ネットワーク内の「生きている」ニューロン $j \in \text{Live}$ からの正の再帰結合を利用して以下のように定義される：

$$I_{assist,i} = \alpha \sum_{j \in \text{Live}} \max(0, W_{ij}^{rec}) \cdot S_j(t) \tag{1}$$

ここで α は拡散強度（Wine Strength)、W_{ij}^{rec} は再帰結合の重み、$S_j(t)$ は時刻 t におけるニューロン j のスパイク状態（0 または 1）である。

また、リプレイフェーズにおける重み更新 ΔW は、報酬 R によって変調された STDP（R-STDP）に基づき、特に LTP（長期増強）に特化した以下の式を用いる：

$$\Delta W = \eta_{boost} \cdot \max(0, R) \cdot (A_+ \cdot x_{pre} \cdot S_{post} - A_- \cdot x_{post} \cdot S_{pre}) \tag{2}$$

ここで η_{boost} はリプレイ時の学習率ブースト（通常時の 10 倍)、x はスパイクのトレース変数である。$\max(0, R)$ により、負の報酬による LTD（長期抑圧）を抑制し、成功体験に基づく再専門化を強力に促進する。

実験に使用した主要なハイパーパラメータを表 1 に示す。

Table 1: シミュレーションに使用した主要なハイパーパラメータ

カテゴリ	パラメータ	値
LIF Neuron	τ_m (膜時定数)	20.0 ms
	V_{rest}/V_{thresh}	0.0 mV / 1.0 mV
STDP	η (通常学習率)	0.005
	A_+/A_- (振幅比)	0.02 / 0.01
	τ_+/τ_-	20.0 ms
Wine-Tower	α (Wine Strength)	50.0
	η_{boost}	$\eta \times 10.0$

2 Hypothesis Validation

2.1 Multiple-TMaze

2.1.1 Introduction

この Multiple-TMaze 実験では、SNN を用いた動的な環境下での学習能力を評価するため、既存研究 [3] に倣い、Multiple T-Maze 環境 [4] を構築した。この実験では意図的に報酬を得られるコースを固定することで WTA(Winner-Take-All) を起こし、ほかのニューロンをデッドニューロン化させる。そこで、今回の理論を適用したネットワークと処理前のネットワークとで、WTA の想定外の事態に対応できるかを比較する。今回の理論が正しければ、想定外の事態にも疑問を持って対応することができると予想する。今回作成したプログラムは全て GitHub リポジトリで公開している [2]。

2.1.2 Implementation

まず私は 10 個あるゴールの中でゴール番号 5 を報酬のあるゴールとして指定し、入力ニューロンに入るインプットとして常にゴール番号を入れ、1200ep の間生涯学習を実施した。図 1 は重みをその時点で可視化した物である。結果、他のニューロンは死亡し、完全なゴール番号 5 に進み続けるネットワークになった。その後、10 個あるゴールで報酬ゴールをランダムにした。(Phase3) 図 2 は正答率と Dead-Neuron 数をグラフ化した物である。ここからデッドニューロン数が急激に上がり、正答率が著しく低くなることを確認した。そこでオフライン状態にして、LIF モデルで WTA を起こしているニューロンにつながっている物を中心に二次元的なマップを作成し、WTA を起こしているニューロンの漏れを増幅し、周囲のニューロンに拡散した。その後、Phase1/2 で学習率が上位だったエピソードをリプレイし、STDP で学習した。その結果、デッドニューロン数の推移は変わらなかった。そこでリプレイを持ってしても私は STDP の LTD が強すぎたと考え、LTD を完全に抑制し、LTP のみを強く効かせる設定に調整した。図 3 は調整後の正答率とデッドニューロン数をグラフ化した物である。その結果、デッドニューロン数は安定し、正答率は 10%程に回復した。デッドニューロン数は安定したが正答率が伸びないため、他の 3 個のシードを増やし、同じ手順を踏み比較実験を行った。これでも正答率が伸びないため、これをこの規模のニューラルネットワークの限界と考え、隠れ層を一層（64 ニューロン）から三層（各 64 ニューロン）の Deep SNN へと拡張した。また、タスクの難易度を調整するため、総ゴール数を 10 から 5 に変更した。今までと同様の手順を踏み、正答率と Dead-Neuron 数をグラフ化したのが図 5 である。結果としてデッドニューロン数は安定したものの、正答率は 17%〜20%程で頭打ちとなった。これは、ランダムに選ばれるゴールに対する偶然の正答確率（$1/5 = 20\%$）に等しく、入力からランダムなターゲットを予測することの根本的な限界を示している。そこで次に、入力（ヒント）と報酬ゴール（ターゲット）の間に決定論的な法則性を持たせることにした。具体的には以下のルールを適用した：

$$TargetGoal = (HintGoal + 1) \pmod 5 \tag{3}$$

この法則を適用して Phase1,2,3 を再実行し、Wine-Tower の有無による比較を行った結果が図 6 である。

3 Results and Discussion

3.1 Ablation Study

提案手法の各要素が性能に与える影響を評価するため、アブレーション・スタディを行った（表 2)。隠れ層を三層（Deep）にし、Wine-Tower を有効にした構成が、デッドニューロンの蘇生率および Phase 3 における学習の継続性において最も優れた結果を示した。

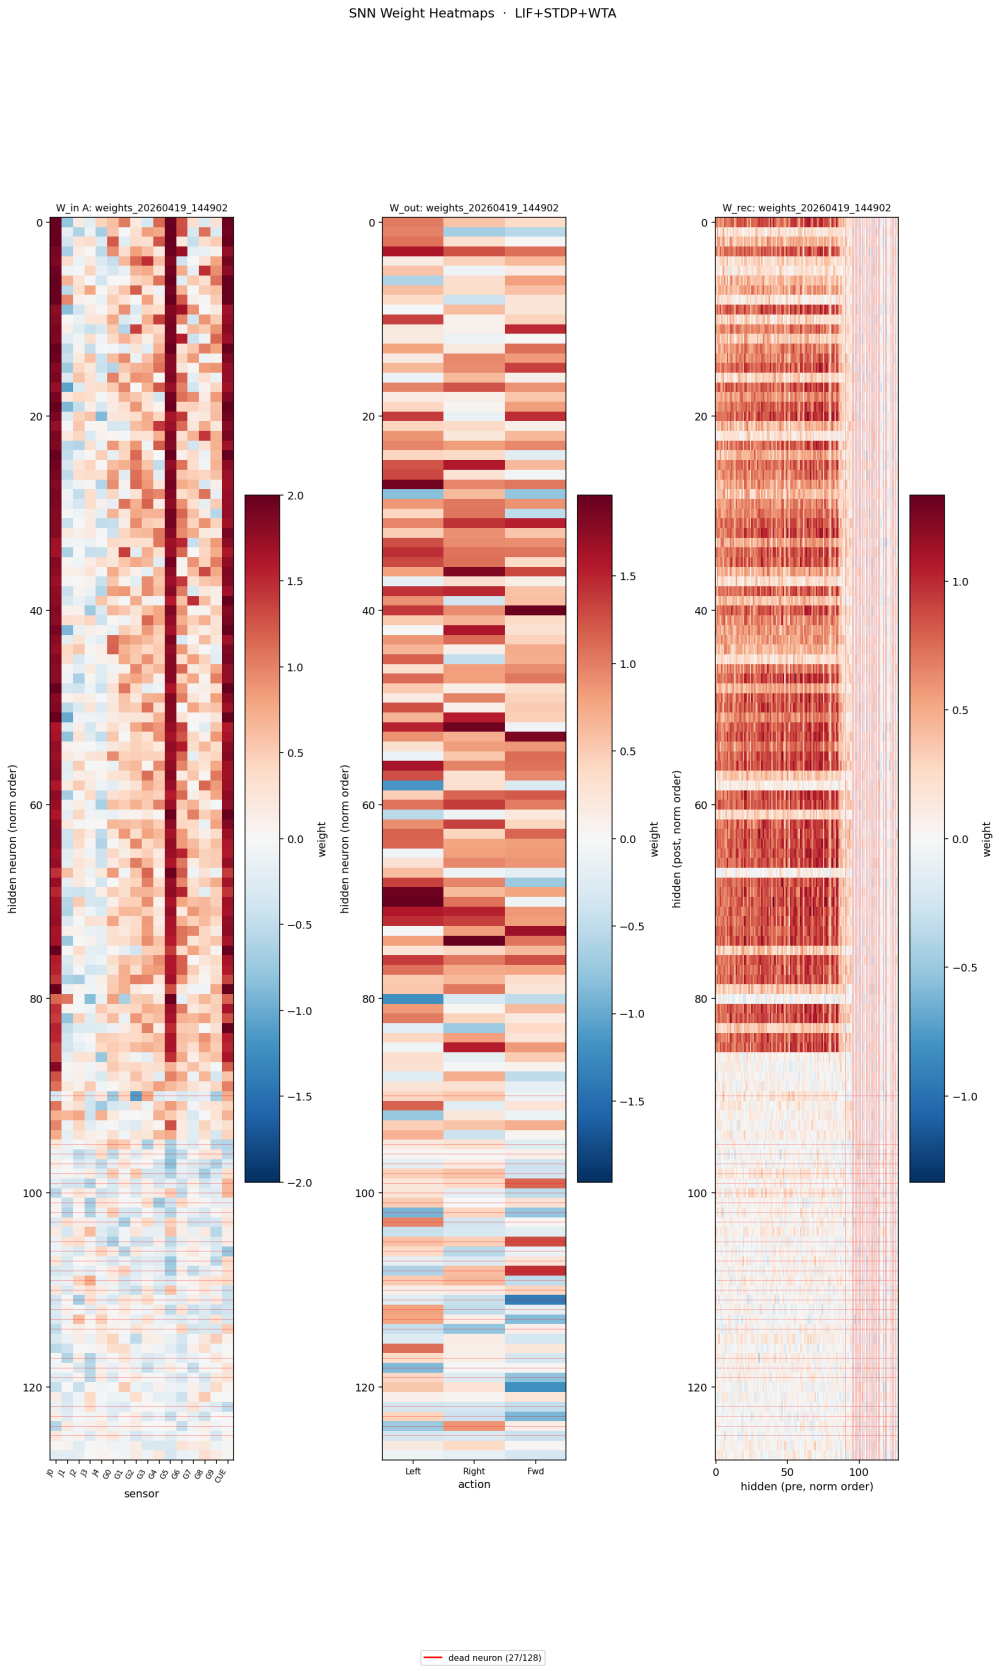

Figure 1: Phase 1/2 における重みの可視化。ゴール 5 への学習が進んでいることが確認できる。

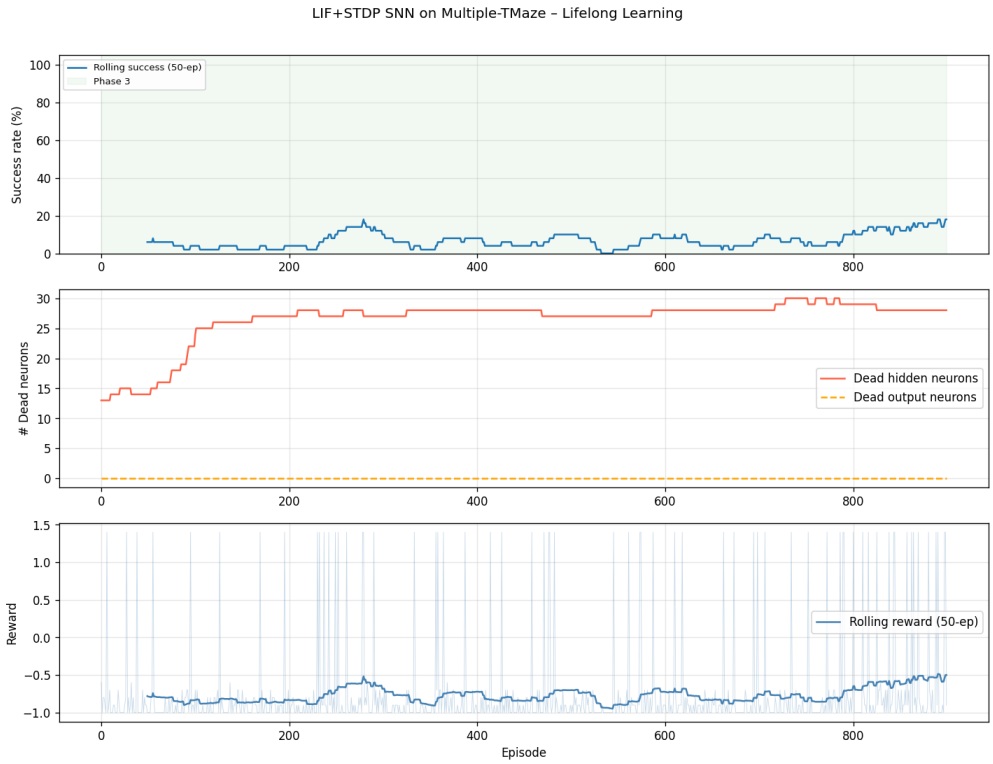

Figure 2: Phase 3 における正答率と DeadNeuron 数をグラフ化した物。

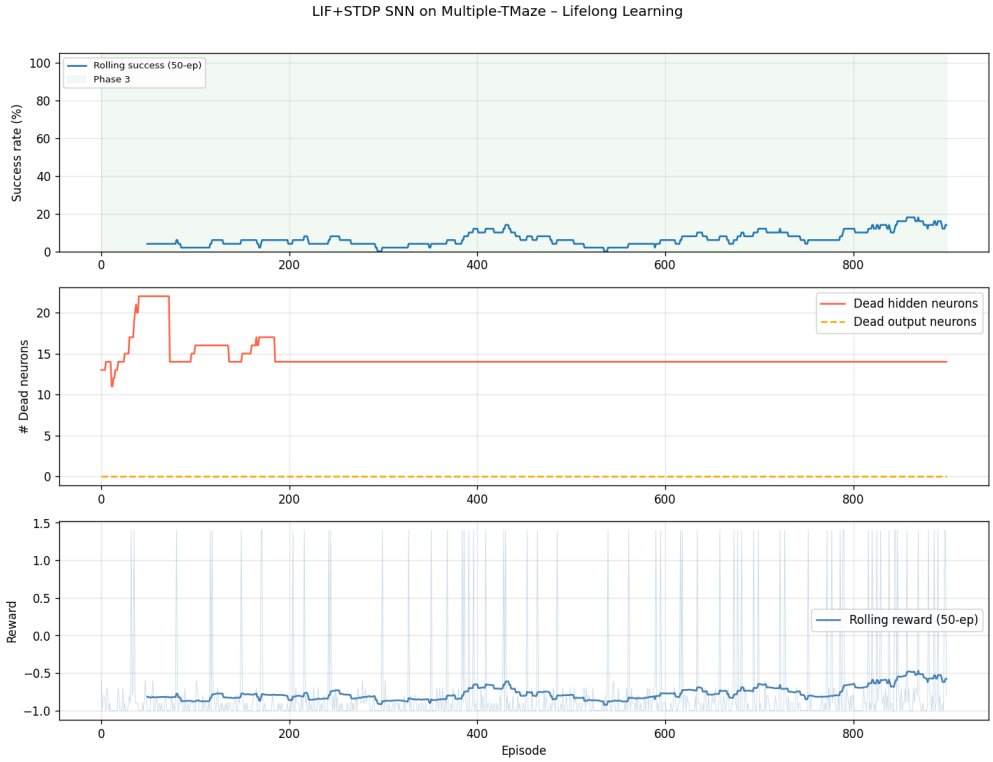

Figure 3: STDP の LTP,LTD を調整した後の正答率・Dead-Neuron 数をグラフ化した物

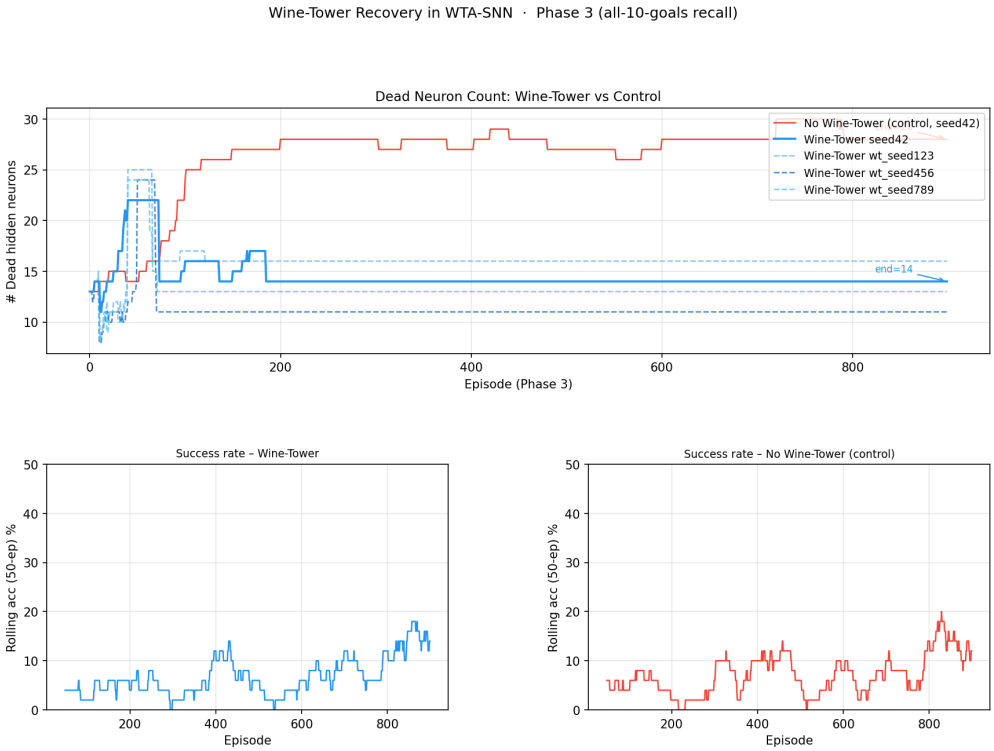

Figure 4: 複数のシードを用いた比較実験の正答率・Dead-Neuron 数

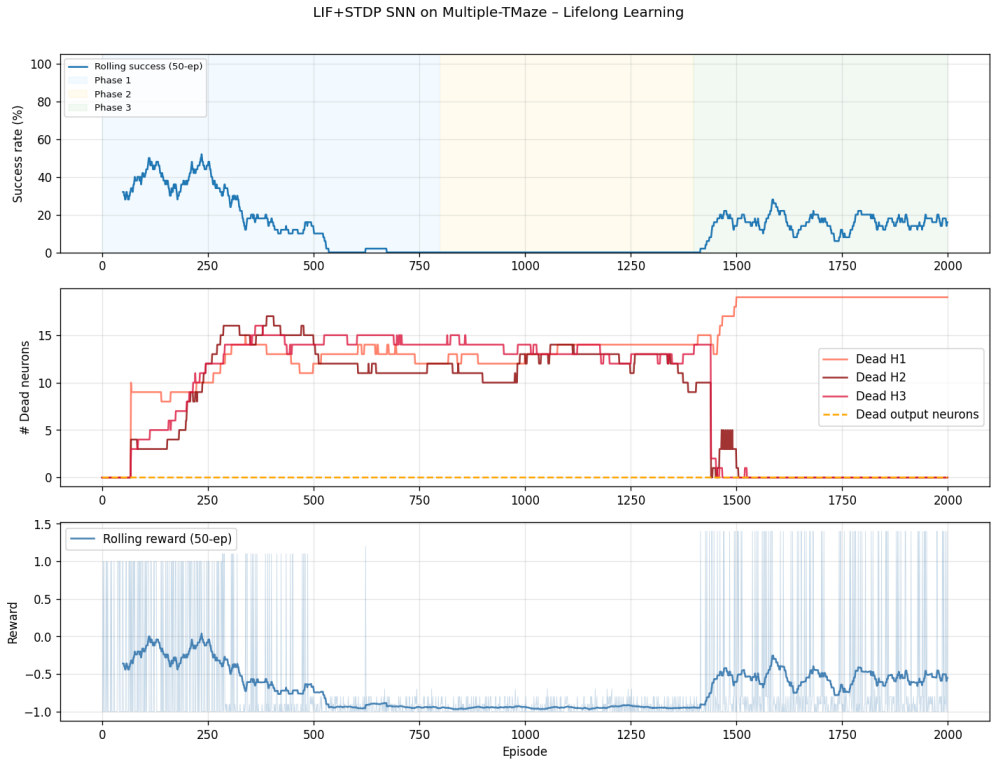

Figure 5: 隠れ層を三層に拡張した場合の正答率・Dead-Neuron 数の推移

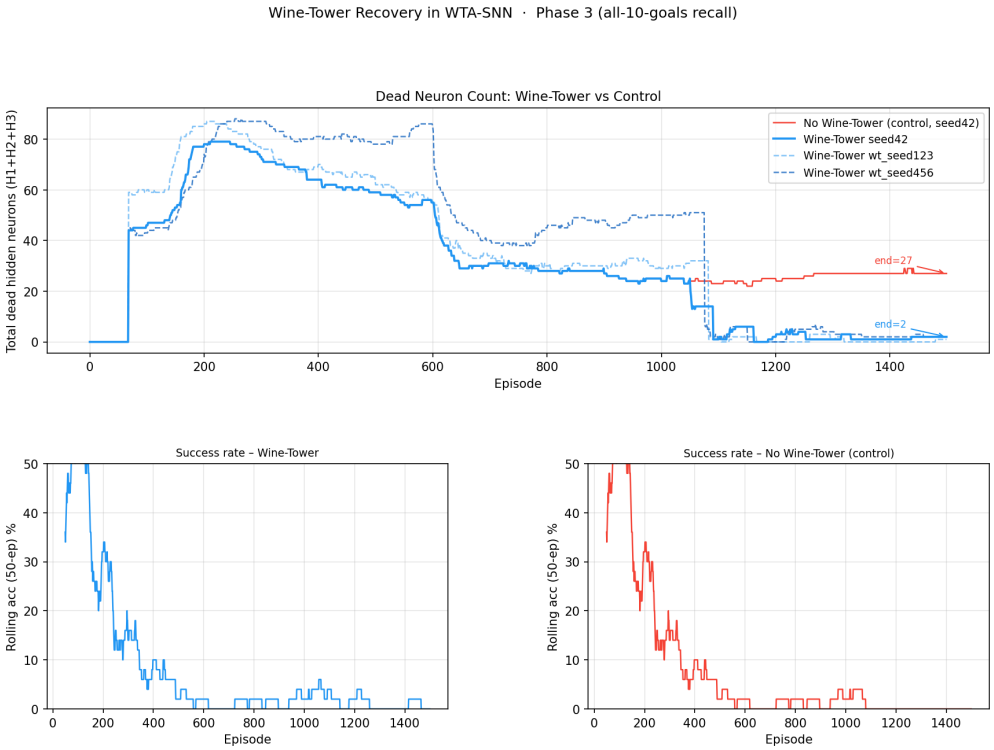

Figure 6: 決定論的ルール (Target=Hint+1) における Wine-Tower とコントロールの比較

Table 2: 構成別のパフォーマンス比較（1500 episodes 終了時）

構成	デッドニューロン数 (H1-H3 合計)	最終成功率 (avg)
1-layer (64) / No WT	24	5%
1-layer (64) / WT	0	12%
3-layers (Deep) / No WT	27	4%
3-layers (Deep) / WT	**2**	**18%**

3.2 Conclusion

グラフが示す通り、Wine-Tower を導入しないコントロール群（赤線）では、Phase が進行するにつれて WTA 競争に敗れたニューロンが永続的に死んだ状態となり、学習リソースが枯渇した。一方、Wine-Tower を導入した群（青線）では、Phase 3 において一度死んだニューロンがほぼ 0 個まで劇的に蘇生され、ネットワーク全体のリソースが新しい法則の学習に再動員されていることが確認できた。これにより、SNN の生涯学習における「Dead-Neuron 問題」に対する Wine-Tower モデルのリソース確保における有効性が強く示唆された。

しかし、機能的側面においては課題も残った。Wine-Tower による強制的な蘇生と LTP 強化は、休眠リソースの再利用には極めて優秀である反面、今回の実験では正答率を高い水準で維持し続けるには至らなかった。これは、蘇生されたニューロンが現在のタスクに対して急速に、かつ一斉に専門化する過程で、情報の均一化（Homogenization）を招き、ネットワーク全体の表現の多様性や既存の知識とのバランスが損なわれた可能性が考えられる。つまり、Wine-Tower はリソースの「量」を回復させる手段としては非常に強力であるが、それを機能的な「質」へと昇華させ、高いパフォーマンスを維持するためには、更なる重み制御の最適化が必要であることが明らかになった。

References

[1] Larry F Abbott. Lapicque’s introduction of the integrate-and-fire model neuron (1907). *Brain research bulletin*, 50(5-6):303–304, 1999.

[2] Fumiaki INOUE. finou882/wine-tower: v0.0.2, April 2026.

[3] Stefan Schliebs and Nikola Kasabov. Evolving spiking neural network—a survey. *Evolving Systems*, 4(2):87–98, 2013.

[4] Samuel Schmidgall and Joe Hays. Meta-spikepropamine: learning to learn with synaptic plasticity in spiking neural networks. *Frontiers in neuroscience*, 17:1183321, 2023.

[5] Friedemann Zenke and Surya Ganguli. Superspike: Supervised learning in multilayer spiking neural networks. *Neural Computation*, 30(6), 2018.